

Pré-processamento de Dados Hoop Vision

Aprendizado de máquinas
Profa. Jaqueline Pugliesi

FATEC Franca - Desenvolvimento de Software Multiplataforma 5º Semestre

Bruno Algarte Inácio
Cristian Tulio Garcia Do Nascimento
Eduardo Vilas Boas Freitas
Rafael Verrísimo da Silva

Base de Dados

Base escolhida: [Season Stats.csv]

Este conjunto de dados contém estatísticas individuais dos jogadores da NBA em cada temporada, desde 1947 até os dias atuais.

1º Passo: Filtragem Temporal

Selecionamos apenas as temporadas entre 1990 e 2022, eliminando registros muito antigos com grande quantidade de dados ausentes. Essa janela temporal também reflete uma era mais moderna e consistente da NBA.

Código:

```
df = pd.read_csv("seasons_stats.csv", encoding='ISO-8859-1')
df_filtered = df[(df['Year'] >= 1990) & (df['Year'] <= 2022)].copy()
df_filtered = df_filtered[df_filtered['G'] > 0]
```

2º Passo: Limpeza e Seleção de Atributos

Como nossa aplicação irá solicitar ao usuário apenas os seguintes dados:

- Posição (Pos)
- Média de Pontos por Jogo (PPG)
- Média de Assistências por Jogo (APG)
- Média de Rebotes por Jogo (RPG)

Eliminamos as demais colunas, reduzindo de 69 para 5 colunas.

Código

```
df_reduzido = df_filtered[['Player', 'Pos', 'PTS', 'AST', 'RPG']].copy()
```

3º Passo: Desenvolvimento do Score Personalizado

Diante da ausência de rótulos de classe na base original, criamos um script em Python que atribui classificações a partir de um sistema de pontuação (score) único para cada posição.

Estratégia de avaliação:

- As métricas foram ajustadas utilizando MinMaxScaler, garantindo valores dentro do intervalo de 0 a 1.
- Cada posição tem pesos distintos aplicados a PPG, APG e RPG, de acordo com a estratégia tática adotada no jogo.

Rótulos atribuídos:

- Score ≥ 0.60 Superstar
- Score ≥ 0.45 All-Star
- Score ≥ 0.25 Role Player
- Score < 0.25 Reserva

Distribuição Final de Rótulos:

- Reserva 9701
- Role Player 3799
- All-Star 861
- Superstar 122

4º Passo: Avaliação Qualitativa

Revisamos a classificação de atletas renomados como:

- LeBron James
- Michael Jordan
- Larry Bird

Todos foram corretamente identificados como Superstars, o que reforça a eficácia da lógica aplicada.

5º Passo: Eliminação de Dados Desnecessários

O campo Player foi excluído da base antes do início do treinamento, uma vez que nomes não têm impacto no aprendizado estatístico e poderiam introduzir viés.

Código:

```
df_sem_nome = df.drop(columns=['Player'])  
df_sem_nome.to_csv("base_sem_nome.csv", index=False)
```

Conclusão

Com a base limpa, normalizada, rotulada e balanceada, finalizamos o pré-processamento dos dados.